

PROJET D'EXAMEN

Machine Learning — Master 2 Génie Informatique

Contrôle terminal du module Machine Learning — session 2026 – 2027

Travail en binôme (ou individuel)

Durée : 2 semaines — Coefficient : équivalent examen écrit

Sommaire

1. Présentation générale	3
2. Sujets proposés (au choix).....	4
3. Cahier des charges méthodologique.....	6
4. Livrables attendus.....	8
5. Grille d'évaluation	9
6. Politique d'utilisation des outils d'IA générative.....	10
7. Calendrier indicatif	11
8. Intégrité académique	12
Annexe — Ressources utiles.....	13

1. Présentation générale

Ce projet constitue l'évaluation terminale du module Machine Learning. Il remplace un examen écrit classique par une mise en situation professionnelle complète : à partir d'un jeu de données réel, chaque binôme doit concevoir, entraîner, évaluer et présenter un système d'apprentissage automatique répondant à une problématique métier précise, en respectant une méthodologie rigoureuse et en produisant une documentation de qualité professionnelle.

L'objectif n'est pas d'obtenir le score le plus élevé sur une métrique donnée, mais de démontrer une maîtrise de bout en bout du cycle de vie d'un projet de machine learning : compréhension du problème, exploration et préparation des données, choix et justification des modèles, évaluation rigoureuse et honnête des résultats, et communication claire de ces résultats à un public technique et non technique.

Objectifs pédagogiques

- Construire un pipeline de machine learning complet, reproductible et documenté.
- Choisir, entraîner et comparer plusieurs familles d'algorithmes de manière justifiée.
- Mettre en œuvre une méthodologie d'évaluation rigoureuse (validation croisée, métriques adaptées, prévention des fuites de données).
- Analyser de façon critique les résultats obtenus : performances, limites, biais potentiels, robustesse.
- Communiquer une démarche et des résultats techniques à l'écrit comme à l'oral.

Modalités générales

- **Groupe de travail** : binôme (le travail individuel est possible sur demande motivée auprès de l'enseignant).
- **Durée** : 2 semaines à partir de la distribution du sujet.
- **Outils** : Python (pandas, scikit-learn, matplotlib/seaborn au minimum) ; l'usage de bibliothèques complémentaires (XGBoost, imbalanced-learn, SHAP, etc.) est encouragé et doit être justifié.
- **Environnement** : Jupyter Notebook ou JupyterLab, dépôt Git pour le suivi du code.

Remarque — Ce sujet est volontairement ouvert : les choix méthodologiques (prétraitement, algorithmes, hyperparamètres) relèvent de la responsabilité du binôme et font partie intégrante de l'évaluation. Un choix simple mais bien justifié et honnêtement évalué est toujours préférable à un choix complexe mal maîtrisé.

2. Sujets proposés (au choix)

Chaque binôme choisit **un seul** des trois sujets suivants et le déclare à l'enseignant avant la fin de la première semaine, selon le principe du premier arrivé premier servi, afin de limiter le nombre de binômes travaillant sur le même sujet. Le cahier des charges méthodologique de la section 3 s'applique identiquement aux trois sujets.

Sujet A — Détection de fraude par carte de crédit

Jeu de données — Credit Card Fraud Detection (Kaggle / Université Libre de Bruxelles). 284 807 transactions de cartes bancaires européennes réalisées en septembre 2013, dont 492 frauduleuses (0,17 % des observations). Variables V1 à V28 issues d'une transformation ACP (anonymisation), plus Time et Amount ; variable cible Class (0 = légitime, 1 = fraude).

Problématique : construire un système capable de détecter les transactions frauduleuses en minimisant à la fois les fraudes non détectées (coût direct) et les fausses alertes (coût opérationnel et expérience client).

Défis spécifiques à traiter explicitement dans le rapport : déséquilibre extrême des classes (pourquoi l'exactitude/accuracy est ici un indicateur trompeur), choix de métriques adaptées (précision, rappel, F1, AUC-PR plutôt que AUC-ROC seule), stratégies de traitement du déséquilibre (pondération des classes, sur/sous-échantillonnage type SMOTE), et discussion du compromis précision/rappel du point de vue métier (quel coût pour une fraude manquée contre une transaction légitime bloquée ?).

Sujet B — Prédiction de la résiliation client (churn)

Jeu de données — Telco Customer Churn (IBM / Kaggle). Environ 7 043 clients d'un opérateur télécom, avec variables démographiques, services souscrits (Internet, téléphonie, options), type de contrat, mode de facturation et montants ; variable cible Churn (le client a-t-il résilié ?).

Problématique : identifier en amont les clients présentant un risque élevé de résiliation afin de cibler des actions de rétention commerciale.

Défis spécifiques à traiter explicitement dans le rapport : encodage d'un grand nombre de variables catégorielles, gestion des valeurs manquantes/incohérentes, interprétabilité orientée métier (quelles variables augmentent le risque de churn, et cette explication est-elle exploitable par une équipe marketing ?), et prise en compte du coût asymétrique d'une erreur (contacter à tort un client fidèle contre ne pas détecter un client sur le départ).

Sujet C — Estimation de la valeur d'un bien immobilier

Jeu de données — California Housing (accessible directement via `sklearn.datasets.fetch_california_housing`) ou, pour un jeu plus riche en variables

catégorielles et qualitatives, Ames Housing (Kaggle). Variables décrivant la localisation, la taille, l'âge et les caractéristiques du bien ; variable cible : prix médian (ou prix de vente pour Ames Housing).

Problématique : prédire la valeur d'un bien immobilier à partir de ses caractéristiques, pour appuyer une estimation automatisée.

Défis spécifiques à traiter explicitement dans le rapport : relations non linéaires entre variables et prix, détection et traitement des valeurs aberrantes, comparaison entre modèles linéaires régularisés (Ridge, Lasso) et modèles à base d'arbres/ensembles, choix et interprétation des métriques de régression (RMSE, MAE, R^2), et analyse des résidus (le modèle se trompe-t-il de façon homogène, ou systématiquement sur certains segments de biens ?).

3. Cahier des charges méthodologique

Quel que soit le sujet choisi, le projet doit couvrir, de manière démontrable dans le notebook et discutée dans le rapport, l'ensemble des étapes suivantes.

3.1 Analyse exploratoire des données (EDA)

- Description statistique des variables (types, distributions, valeurs manquantes, valeurs aberrantes).
- Visualisations pertinentes (distributions, corrélations, relations avec la variable cible).
- Identification explicite des difficultés propres au jeu de données choisi (déséquilibre de classes, variables catégorielles, valeurs manquantes, colinéarité, etc.).

3.2 Prétraitement et ingénierie des caractéristiques

- Traitement justifié des valeurs manquantes et aberrantes.
- Encodage des variables catégorielles, normalisation/standardisation des variables numériques selon les modèles utilisés.
- Construction éventuelle de nouvelles variables (feature engineering) et justification de leur pertinence.
- Découpage rigoureux entraînement/validation/test (ou validation croisée), effectué **avant** tout apprentissage de transformation (normalisation, encodage, sur-échantillonnage) afin d'éviter toute fuite de données (data leakage).

3.3 Modélisation

Le binôme doit entraîner et comparer **au moins trois algorithmes** de familles différentes, par exemple :

- Un modèle linéaire ou régularisé (régression logistique, Ridge, Lasso selon le sujet).
- Un modèle à base d'arbres ou d'ensemble (Random Forest, Gradient Boosting, XGBoost/LightGBM).
- Un troisième modèle au choix (SVM, k plus proches voisins, réseau de neurones simple type MLP, etc.), servant de point de comparaison supplémentaire.

Pour chaque modèle, le choix de l'algorithme, de ses hypothèses et de ses limites doit être explicité — un algorithme ne doit jamais être utilisé « en boîte noire » sans justification.

3.4 Sélection de modèle et recherche d'hyperparamètres

- Validation croisée (k-fold, ou stratifiée pour les problèmes de classification déséquilibrés).
- Recherche d'hyperparamètres (GridSearchCV, RandomizedSearchCV, ou tout autre outil tel qu'Optuna), avec justification de l'espace de recherche exploré.
- Comparaison honnête des modèles sur le même protocole d'évaluation.

3.5 Évaluation rigoureuse

- Choix de métriques adaptées au problème (voir les défis spécifiques de chaque sujet, section 2) et justification de ce choix.
- Évaluation finale sur un jeu de test tenu à l'écart de tout le processus de sélection de modèle.
- Pour les problèmes de classification : matrice de confusion et, selon le sujet, courbes ROC et Précision-Rappel. Pour la régression : analyse des résidus.
- Vérification explicite de l'absence de fuite de données et discussion de la stabilité des résultats (variance entre les plis de validation croisée).

3.6 Interprétabilité

- Analyse de l'importance des variables (feature importance native, permutation importance, ou valeurs de Shapley via la bibliothèque SHAP).
- Mise en relation des résultats obtenus avec la problématique métier énoncée dans le sujet choisi.

3.7 Analyse critique et discussion

- Limites du meilleur modèle retenu et cas d'erreur typiques.
- Biais potentiels du jeu de données (représentativité, période de collecte, biais historiques) et conséquences possibles d'un déploiement en production.
- Pistes d'amélioration concrètes (données additionnelles, autres approches, collecte de retours utilisateurs, etc.).

Remarque — Cette section est déterminante dans l'évaluation : un binôme capable d'expliquer honnêtement pourquoi son modèle se trompe, et dans quelles conditions il ne faut pas lui faire confiance, sera mieux noté qu'un binôme qui ne présente que des résultats favorables sans recul critique.

4. Livrables attendus

1. **Notebook Jupyter (.ipynb)**, exécutable de bout en bout sans erreur, organisé en sections claires (EDA, prétraitement, modélisation, évaluation, interprétabilité), avec des cellules Markdown expliquant la démarche à chaque étape.
2. **Rapport écrit (PDF, 8 à 12 pages hors annexes)**, structuré en introduction, présentation des données, méthodologie, résultats, discussion critique et conclusion — rédigé pour être compréhensible sans avoir le notebook sous les yeux.
3. **Dépôt Git** contenant le code source, un fichier README expliquant comment reproduire les résultats, et la liste des dépendances (requirements.txt ou environment.yml).
4. **Soutenance orale** de 15 minutes (présentation, 8 à 10 diapositives) suivie de 10 minutes de questions, devant l'enseignant (et éventuellement un jury).

Remarque — Le notebook, le rapport et le dépôt Git doivent raconter la même histoire de façon cohérente. Toute divergence significative entre les résultats présentés dans le rapport et ceux réellement reproductibles à partir du code sera pénalisée.

5. Grille d'évaluation

L'évaluation est notée sur 20 points, répartis selon la grille ci-dessous. Cette grille est communiquée à titre indicatif ; l'enseignant peut l'ajuster à la marge en fonction du sujet choisi.

Critère	Points
Analyse exploratoire des données et qualité du prétraitement	3
Pertinence et rigueur de la modélisation (diversité des algorithmes, méthodologie)	4
Rigueur de l'évaluation (métriques adaptées, validation croisée, absence de fuite de données)	4
Interprétabilité et analyse critique des résultats	3
Qualité du code (lisibilité, reproductibilité, bonnes pratiques, dépôt Git)	2
Qualité rédactionnelle du rapport écrit	2
Soutenance orale (clarté, réponses aux questions)	2
Total	20

6. Politique d'utilisation des outils d'IA générative

L'usage d'outils d'IA générative (assistants de code, chatbots) est **autorisé** pour ce projet, à titre d'aide à la rédaction, au débogage ou à la recherche documentaire, dans les conditions suivantes :

- **Transparence** : le rapport doit comporter une courte section « Utilisation d'outils d'IA » précisant les outils utilisés et pour quelles tâches (ex. : génération d'un squelette de fonction, reformulation d'un paragraphe, débogage d'une erreur).
- **Appropriation** : chaque membre du binôme doit être capable, en soutenance, d'expliquer et de justifier tout choix méthodologique ou toute ligne de code présente dans le rendu, qu'elle ait été écrite avec ou sans assistance. L'incapacité à expliquer un choix sera pénalisée, indépendamment de son origine.
- **Analyse critique non délégable** : la section 3.7 (analyse critique et discussion des limites) doit refléter la compréhension propre du binôme des résultats obtenus sur son jeu de données spécifique ; une analyse générique manifestement non ancrée dans les résultats réels du projet sera considérée insuffisante.
- **Responsabilité du contenu** : comme pour toute source utilisée, le binôme reste entièrement responsable de l'exactitude et de la pertinence de ce qui est rendu, y compris le contenu produit avec assistance d'une IA.

7. Calendrier indicatif

Les dates ci-dessous sont indicatives ; elles doivent être confirmées et communiquées par l'enseignant responsable du module lors de la distribution du sujet.

Étape	Échéance indicative
Distribution du sujet	Semaine 1, jour 1
Déclaration du sujet choisi (A, B ou C) et constitution des binômes	Fin de semaine 1
Remise du notebook, du rapport et du dépôt Git	Fin de semaine 2
Soutenances orales	Debut semaine 3

8. Intégrité académique

Chaque binôme doit produire un travail original. La réutilisation de code ou d'analyses provenant d'autres sources (dépôts publics, corrections d'années antérieures, autres binômes) doit être explicitement citée ; l'absence de citation d'une source substantiellement reprise constitue un manquement à l'intégrité académique et sera traitée selon le règlement de l'établissement. Les binômes travaillant sur le même sujet sont invités à la vigilance : des similarités marquées entre deux rendus (structure du code, choix de rédaction, résultats) feront l'objet d'un examen contradictoire.

Annexe — Ressources utiles

Jeux de données

- Credit Card Fraud Detection : kaggle.com/mlg-ulb/creditcardfraud
- Telco Customer Churn : kaggle.com/blatchar/telco-customer-churn
- California Housing : intégré à scikit-learn
(`sklearn.datasets.fetch_california_housing`)
- Ames Housing : kaggle.com/prevek18/ames-housing-dataset

Documentation technique

- Documentation scikit-learn (modèles, sélection de modèle, métriques) : scikit-learn.org
- Bibliothèque imbalanced-learn (techniques de rééquilibrage de classes) : imbalanced-learn.org
- Bibliothèque SHAP (interprétabilité) : shap.readthedocs.io
- Documentation XGBoost / LightGBM pour les modèles de boosting.

Questions fréquentes

- **Peut-on changer de sujet en cours de projet ?** Non, sauf accord explicite de l'enseignant en cas de difficulté technique majeure (ex. : jeu de données inaccessible).
- **Un score élevé sur la métrique principale garantit-il une bonne note ?** Non : la méthodologie, l'honnêteté de l'évaluation et la qualité de l'analyse critique comptent au moins autant que la performance brute du modèle.
- **Le troisième algorithme de la section 3.3 doit-il être compétitif ?** Non : il peut volontairement être moins performant, à condition que cela soit analysé et expliqué (par exemple, pourquoi un k-NN se comporte mal sur des données de grande dimension).